

Tugas 2

Latihan Data Cleaning, Data Preprocessing, Modelling Data dan Evaluation Data



Dosen Pengampu : Adhy Rizaldy, S.Kom., M.Kom

| | |
|-------|------------------------|
| Nama | : Fajrul Hidayat Amini |
| NIM | : 60900123019 |
| Kelas | : A |

**JURUSAN SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI ALAUDDIN MAKASSAR**

2025

A. Import Data

dataset diabetes.csv dimuat ke dalam program menggunakan pandas. Tujuan tahap ini adalah untuk memastikan data berhasil terbaca dan memahami struktur awalnya—termasuk jumlah baris, kolom, dan apakah ada nilai nol atau kosong yang bisa mengganggu analisis.

```
Tahap 1: Import Dataset
Jumlah baris dan kolom: (768, 9)

5 baris pertama:
   Pregnancies  Glucose  BloodPressure  SkinThickness  Insulin   BMI  DiabetesPedigreeFunction  Age  Outcome
0            6      148             72             35         0   33.6              0.627         50         1
1            1       85             66             29         0   26.6              0.351         31         0
2            8      183             64              0         0   23.3              0.672         32         1
3            1       89             66             23        94   28.1              0.167         21         0
4            0      137             40             35       168   43.1              2.288         33         1

Jumlah nilai nol pada tiap kolom:
Pregnancies      111
Glucose           5
BloodPressure     35
SkinThickness    227
Insulin          374
BMI              11
DiabetesPedigreeFunction  0
Age              0
Outcome          500
dtype: int64
```

B. Data Cleaning

Tahap cleaning dilakukan karena beberapa kolom, seperti **Glucose**, **BloodPressure**, **SkinThickness**, **Insulin**, dan **BMI**, memiliki nilai **0**. Nilai nol ini kemudian **diganti dengan nilai median** dari masing-masing kolom agar distribusi data tetap seimbang.

```
Tahap 2: Data Cleaning
Nilai nol setelah cleaning:
Pregnancies      111
Glucose           0
BloodPressure     0
SkinThickness     0
Insulin           0
BMI               0
DiabetesPedigreeFunction  0
Age              0
Outcome          500
dtype: int64

Statistik deskriptif setelah cleaning:
   Pregnancies  Glucose  BloodPressure  ...  DiabetesPedigreeFunction  Age  Outcome
count  768.000000  768.000000  768.000000  ...  768.000000  768.000000  768.000000
mean     3.845052  121.656250   72.386719  ...    0.471876   33.240885    0.348958
std     3.369578   30.438286   12.096642  ...    0.331329   11.760232    0.476951
min      0.000000   44.000000   24.000000  ...    0.078000   21.000000    0.000000
25%      1.000000   99.750000   64.000000  ...    0.243750   24.000000    0.000000
50%      3.000000  117.000000   72.000000  ...    0.372500   29.000000    0.000000
75%      6.000000  140.250000   80.000000  ...    0.626250   41.000000    1.000000
max     17.000000  199.000000  122.000000  ...    2.420000   81.000000    1.000000
```

C. Data Preprocessing

Deteksi Outlier (IQR) digunakan untuk melihat apakah ada nilai-nilai ekstrem di setiap kolom.

Standardisasi (Z-Score) agar semua fitur dinormalisasi agar memiliki rata-rata mendekati 0 dan standar deviasi mendekati 1.

```
Tahap 3: Deteksi Outlier (IQR)
Pregnancies: 4 outlier terdeteksi
Glucose: 0 outlier terdeteksi
BloodPressure: 14 outlier terdeteksi
SkinThickness: 35 outlier terdeteksi
Insulin: 49 outlier terdeteksi
BMI: 8 outlier terdeteksi
DiabetesPedigreeFunction: 29 outlier terdeteksi
Age: 9 outlier terdeteksi

Tahap 4: Pemisahan Fitur dan Target
Jumlah fitur: 8
Jumlah target (Outcome=1): 268 | (Outcome=0): 500

Tahap 5: Standardisasi (Z-Score)
Rata-rata fitur setelah standarisasi (mendekati 0): 0.0
Standar deviasi fitur setelah standarisasi (mendekati 1): 1.0
```

data juga dibagi menjadi tiga bagian yaitu, 60% untuk training, 20% untuk validation, 20% untuk testing.

```
=== Tahap 6: Pembagian Data ===
Training set: 460 data
Validation set: 154 data
Testing set: 154 data
```

D. Modelling Data

Dua model digunakan untuk perbandingan:

Random Forest Classifier, yaitu model berbasis kumpulan pohon keputusan (ensemble learning) yang cenderung lebih akurat pada data kompleks.

```
Training Model - Random Forest
Model Random Forest selesai dilatih.

[Evaluasi Random Forest - Validation Set]
Accuracy: 0.7208
Precision: 0.6222
Recall: 0.5185
F1-Score: 0.5657
ROC-AUC: 0.6743
Confusion Matrix:
[[83 17]
 [26 28]]
```

Logistic Regression, yaitu model linear yang lebih sederhana dan mudah ditafsirkan.

```
Training Model - Logistic Regression
Model Logistic Regression selesai dilatih.

[Evaluasi Logistic Regression - Validation Set]
Accuracy: 0.7532
Precision: 0.66
Recall: 0.6111
F1-Score: 0.6346
ROC-AUC: 0.7206
Confusion Matrix:
[[83 17]
 [21 33]]
```

E. Evaluasi Data

Tahap ini menilai seberapa baik model dalam memprediksi seseorang terkena diabetes. Metrik yang digunakan meliputi Accuracy, Precision, Recall, F1-Score, dan ROC-AUC.

Tahap 8: Evaluasi Akhir (Test Set)

[Random Forest - Test Set]

Accuracy: 0.7208

Precision: 0.5926

Recall: 0.6038

F1-Score: 0.5981

ROC-AUC: 0.693

Confusion Matrix:

[[79 22]

[21 32]]

[Logistic Regression - Test Set]

Accuracy: 0.7532

Precision: 0.6923

Recall: 0.5094

F1-Score: 0.587

ROC-AUC: 0.6953

Confusion Matrix:

[[89 12]

[26 27]]

PS D:\Kuliah\Semester 5\Data Mining\Teori\Tugas> █